

状态:离职

邮箱:

电话:

性别:

求职岗位:AI应用开发工程师

工作经验:3年

学历:本科

薪资:面议

年龄:

专业技能

- 熟练Python核心语法，常用数据结构与编程规范，掌握面向对象、函数式编程，掌握异常处理、代码调试等工程开发能力
- 熟悉主流大模型生态，可独立对接OpenAI、DeepSeek、通义千问等多厂家API接口，适配各类模型调用场景
- 熟练Prompt工程，擅长结构化、动态化提示词设计，掌握同步/异步流式输出开发
- 熟练运用LangChain框架开发，掌握模型调用、提示词模板、自定义工具封装与链式编排，可快速搭建各类大模型基础应用
- 熟悉 A2A 通信协议，理解多智能体协作范式，掌握 Agent 间的任务分发与协同决策机制，能设计复杂的多智能体交互架构
- 掌握 MCP 标准，能够通过标准化接口实现大模型与外部数据源、工具及系统的无缝集成，构建高可用的互联应用
- 掌握 Agent Skills 通用架构与规范：熟练配置技能元数据、上下文触发条件及指令封装，实现 Agent 能力的模块化扩展与动态加载。
- 熟练RAG全流程开发，涵盖文档解析、文本清洗、智能分块、Embedding向量化等数据预处理核心流程
- 熟练掌握基于RagAS框架构建RAG评估系统，对上下文召回率、答案相关性、忠实度等指标进行量化分析。
- 熟练LangGraph状态图开发，熟练节点、边、条件路由配置，可搭建逻辑复杂的智能Agent工作流
- 掌握状态持久化、断点续跑机制，支持多步骤、可回溯、稳定的智能任务编排流程搭建
- 具备自主决策Agent开发经验，可实现模型自主判断、工具调用、任务执行的全流程闭环能力
- 掌握大模型轻量化微调技术，熟练LoRA、全量微调方案，完成开源模型行业领域适配
- 掌握微调数据集全流程构建，涵盖数据清洗、筛选、格式化标准，保障模型训练效果

工作经验

上海天舟信息技术有限公司

AI应用开发工程师

2024/09 - 2026/07

- 参与 AI 产品需求分析与技术方案选型，主导核心功能模块的设计与开发。
- 协助搭建、调优向量数据库，优化存储与检索效率，支撑应用快速响应。
- 参与智能体核心模块开发，完成业务逻辑与大模型智能功能融合联调。
- 负责数据收集、清洗、日常 Bug 修复等工作；

上海数全软件有限公司

AI应用开发工程师

2023/07 - 2024/08

- 负责技术的调研，和整体流程的设计

- 分析并解决开发中所遇到的技术问题
- 根据项目业务需求，通过编码独立实现业务逻辑

项目经历

鹿淘购智能助手

AI应用开发工程师

2025/11 - 2026/06

技术架构:

Python, LangGraph, LangChain, FastAPI, A2A Protocol, PostgreSQL, Elasticsearch, Qwen3-Max, Docker, MCP Server等

项目描述:

针对电商全链路复杂的交互场景，构建基于 LangGraph 的多智能体协同客服平台。系统涵盖商品导购、营销转化、交易下单及售后维权四大核心环节，将商品、营销、订单、售后等模块封装成垂直领域独立的 Agent。底层采用 MCP 协议标准化对接 Elasticsearch 商品库与 MySQL 订单库，利用 A2A 协议实现跨域数据自动流转（如订单与物流的无缝衔接）。该平台有效解决了传统客服在处理长链路任务时的上下文丢失与数据割裂问题，大幅提升了复杂场景下的用户自助解决率与转化率。

职责描述:

1.多智能体编排与状态管理:基于 LangGraph 编排多垂直 Agent 协同工作，利用全局状态共享机制打通各环节数据壁垒，解决复杂电商场景下的长链路上下文丢失等问题。

2.意图路由与分发:基于 LangGraph 构建动态路由节点，利用 LLM 精准识别用户 Query 意图并分发至对应 Agent，实现复杂业务的自动化处理。

3.会话持久化:设计基于 PostgreSQL 的多轮对话持久化方案，通过结构化存储实现会话状态的原子性读写与一致性查询，确保用户在跨天、跨设备的长流程交互中数据零丢失，支持历史上下文的高效回溯。

4.MCP 工具服务与高可用保障:开发 MCP Server 统一封装 Elasticsearch（商品库）、MySQL（订单库）及第三方物流 API；在网关层实施数据标准化与熔断降级策略，保障了核心业务链路在外部依赖不稳定时的高可用性。

5. A2A 跨域协同与效率提升:基于 A2A 协议重构订单与物流系统的交互逻辑，实现 Agent 间的自主握手与参数透传（如自动传递订单号查轨迹）；将原本割裂的系统打通，使用户“查物流”无需分步提问，售后咨询平均处理时长从10分钟骤降至1分钟内。

6. 负责多智能体系统的效果评估:针对复杂的电商业务流程,构建了包含多种情况的测试用例集。测试了系统在意图识别和工具调用上的准确性以及任务完成率。通过模拟用户真实操作路径（如查件、改址、退换货）,评估Agent在长链路交互中的成功交付能力，确保核心业务场景的任务完成率稳定在95%以上。

项目成果

1.核心指标达成：系统上线后覆盖了 90% 的常见售后场景（物流、售后政策、商品咨询），人工客服日均接待量下降 40%。

2.业务价值落地:智能导购模块的询单转化率提升至 15%+，有效证明了多智能体系统在电商场景下的商业变现能力。

智信金融助手

AI应用开发工程师

2025/05 - 2025/10

技术架构:

Python, LangChain, Milvus, BGE-M3, Qwen3-14B, LoRA, BM25, FastAPI, RagAS,MySQL,Redis等

项目描述:

基于金融机构复杂的业务咨询场景，构建基RAG 架构的智能问答系统。系统覆盖理财产品查询、信贷政策解读、开户流程指引及合规风控等核心业务。通过实时检索内部知识库与监管文档增强大模型生成能力，解决通用模型在金融垂直领域幻觉率高的问题。同时，系统自动化处理高并发的客户咨询，大幅降低人工坐席压力，实现 7x24 小时专业级金融服务。

职责描述:

- 1.意图识别与动态路由:基于 BERT 微调训练意图识别模型，区分通用问题与专业咨询，动态路由至 5 种检索策略，提升复杂 Query 处理精度
- 2.检索链路优化:检索前增加 Query 改写环节，将口语化提问改写为检索友好表述，并做多查询扩展；落地 BM25 + BGE-M3 混合检索与重排序架构，显著提升复杂 Query 召回精度
- 3.多级缓存架构:设计 Redis + MySQL 多级缓存，对高频问答进行缓存，命中缓存直接返回，热点问答响应降至毫秒级
- 4.主导检索链路和优化：实施混合检索与重排序架构，解决单一检索方式的局限性，显著提升复杂 Query 的召回精度与回答质量。
- 5.搭建 RAG 效果评估体系:引入 Ragas 框架对上下文相关性，召回率，忠实度，答案相关性等核心指标，实现系统回答质量的评估。

项目成果：系统自动化处理高并发客户咨询，实现 7x24 小时专业级金融服务，有效降低人工坐席压力。

优保问答助手 AI应用开发工程师 2024/10 - 2025/04

技术架构:

Python, LangChain, Milvus,LoRA, OCR, BGE-M3, BM25, FastAPI, RagAS等

项目描述:

构建面向保险垂直领域的 RAG 问答系统。利用动态知识库增强大模型上下文理解能力，解决复杂条款查询中的检索准确率与幻觉问题，提供可溯源的专业业务支持。

职责描述:

- 1.文档解析与知识库构建:针对保险文档格式混乱等问题，设计并实现了自动化文档解析链路；完成了从高质量文本提取到语义分块的全流程处理，成功构建了覆盖核心产品的专属向量知识库。
- 2.混合检索策略设计：基于 Milvus 向量数据库，设计了 BM25 关键词检索与 BGE-M3 语义检索相结合的多路召回架构；针对疾病定义等专有名词优化检索权重，显著提升了复杂条款查询的召回准确率与鲁棒性。
- 3.RAG 效果量化评估与调优：引入 RagAS 评估框架搭建自动化流水线，重点监控“忠实度”与“答案相关性”指标；通过持续迭代 Prompt模板与检索策略，有效抑制了模型幻觉，使系统问答准确率提升了约 18%。
- 4.模型微调与优化:采用 LoRA 高效微调策略，增强模型在保险垂直领域的指令遵循能力与回答专业度。

基于 RAG 的企业知识库增强自助服务系统 AI应用开发工程师 2024/05 - 2024/08

技术架构:

Python, LangChain, Milvus, BGE-M3, LoRA, FastAPI, Qwen2.5-7B,RagAS等

项目描述

传统 FAQ 系统在 HR 政策、薪酬福利等高频咨询场景中存在准确率低、知识更新滞后等问题。本项目构建融合结构化检索与 RAG 的智能问答系统，为企业员工提供精准自助服务，同时支撑 HR 效率提升与管理层战略决策。

职责描述:

1.RAG 全链路构建： 搭建“检索→Prompt 拼接→Qwen2.5-7B 生成→流式输出”完整流程，支持上下文感知对话，保障回答连贯性与低延迟体验。

2.意图识别与动态路由： 集成在线大模型 API 作为中枢，实时分析 Query 语义并精准分类；根据结果动态路由至对应垂直知识库，解决复杂业务场景下的指向性模糊问题。

3.自动化评估体系： 基于 RagAS 设计包含忠实度、相关性等维度的评估数据集，量化分析检索与生成质量；通过反馈闭环优化切片策略与召回算法，使核心场景回答准确率提升 20% 以上。

4.检索策略深度优化： 引入 BGE-M3 模型进行混合检索与重排序（Rerank），结合关键词匹配与语义向量优势，有效解决长尾问题召回不准的痛点，将 Top-5 召回率提升至 90% 以上。

日电商城智能信息抽取系统

AI应用开发工程师

2024/01 - 2024/04

技术架构：

Python, Transformers, Llama-Factory, Qwen2-7B, LoRA, Prompt Engineering等

项目描述：

针对家电商城海量非结构化文本难以利用的问题，基于 Qwen2-7B 大模型与 Llama-Factory 框架，构建端到端结构化信息抽取系统。解决传统小模型泛化能力弱的问题，实现买家意图、商品偏好等核心要素的精准提取，为运营决策提供高价值数据支撑。

责任描述：

- 数据标准化构建：** 定义基于 Json Schema 的标准化输出结构，负责文档清洗与标注，累计产出 5500 条高质量样本，确保数据贴合业务场景。
- 训练策略优化：** 将全量微调迭代为 LoRA 高效微调模式，使训练效率提升 3 倍；初期将信息抽取 F1 值优化至 82.3%，显著降低算力成本。
- 数据集增强迭代：** 采用同义词替换、LLM 辅助生成等方式扩充样本，构建 1200+ 条黄金训练集，推动 F1 值进一步提升至 88.7%。
- 模型性能验证：** 主导独立测试验证，最终模型 F1 值达 91.8%，核心字段（品牌、品类、属性）召回率超 91%，完全满足业务上线标准。

教育经历

江西科技师范大学

软件工程·本科

2019/09 - 2023/06

自我评价

- 有较强的逻辑思维能力，善于分析、归纳、解决问题。
- 积极参加集体活动，具有很好的团队沟通能力。
- 工作勤奋主动，学习能力强，有强烈责任心，能主动学习钻研与工作相关的知识和技术。
- 心态阳光，有良好的抗压能力和自我调节能力。