

— 智能应用开发工程师

男 · 24岁 本科 · 计算机科学与技术 浙江台州 城市：

工作经历

义乌家居日用电商 | 软件开发岗 · AI 软件工程师 | 2023.7 — 2026.5

教育经历

浙江财经大学 | 计算机科学与技术 · 本科 | 2019.9 — 2023.6

技术专长

- 精通 Python 异步编程及 FastAPI 框架，擅长 SSE 流式接口与 RESTful API 设计与开发
- 深入掌握 LangChain + LangGraph 多智能体 workflow，涵盖路由分发、条件分支、并行执行、子图嵌套与流式输出
- 具备 RAG 系统全链路开发经验：文档解析、向量化存储、混合检索、重排序与答案生成
- 熟练运用 Milvus 向量数据库，设计稠密+稀疏双向量混合检索 Schema，完成集群部署与调优
- 掌握 Nacos 服务注册发现与配置中心，实现微服务治理及配置热更新
- 熟练运用 Redis，覆盖 Token 缓存、分布式停止标记、令牌桶限流等场景
- 熟悉 Spring Cloud Gateway 网关开发，具备 JWT 认证、限流、熔断等流量治理实战经验

项目经历

智答 2026.1 — 2026.4

项目简介：企业级智能知识问答与内容管理系统。针对大模型回答失真问题持续迭代优化，落地 FAQ 精准匹配 + 知识库检索双引擎架构，支持对话历史留存与流式实时输出。核心服务短视频创作、直播运营、内容策划等业务线，为一线团队提供高效的知识检索与智能问答能力。

技术栈：Python 3.10 · FastAPI · LangChain · Qwen-Plus · BGE-M3 · BGE-Reranker-Large · Milvus 2.4 · BERT · MySQL · Redis · RAGAS · Uvicorn

个人职责：

- 向量数据库搭建与优化：基于 Docker Compose 实现 Milvus、Redis 等组件一键部署；设计稠密+稀疏双向量存储结构，通过向量融合与重排序大幅提升检索精度与内容匹配准确性。
- 意图识别与智能分流：基于 BERT 微调业务咨询/通用知识二分类模型，完成数据集划分与模型训练；实现通用问题直连大模型、业务问题检索知识库的智能分流，显著提升响应效率。
- 双引擎检索架构落地：搭建 BM25 精准 FAQ 匹配 + Milvus 混合检索兜底的双检索机制，设置合理匹配阈值；依托 MySQL 管理多轮对话历史，保障问答上下文连贯性。

项目亮点：

- 融合稠密语义、稀疏词汇、关键词三路检索，互补单一检索盲区，大幅提升复杂场景检索准确率
- 创新父子分块策略——子块精准检索、父块补充上下文，兼顾检索精度与内容完整性
- 实现业务场景智能分流，减少无效知识库检索，降低响应耗时

数智商脉 2025.9 — 2025.12

项目简介：从零搭建企业级 AI 智能体中台，打通智能体编排、微服务治理、协议标准化、知识库检索全链路。采用路由工作流与 A2A 双架构协同模式，实现网关统一管控、标准化工具服务、智能检索增强等核心能力，支撑业务推荐、投放决策、智能咨询、自动回复等多元化场景，大幅提升 AI 业务落地效率。

技术栈：Python 3.13 · FastAPI · LangGraph 1.0 · LangChain 1.1 · Qwen3-Max · Spring Cloud Gateway · Nacos · A2A · MCP · Redis · MySQL · PostgreSQL · Feign · WebClient · SSE

个人职责：

- 多智能体架构编排：基于 LangGraph 搭建 6 个子智能体路由工作流，结合 A2A 协议构建 5 个独立微服务集群；依托大模型动态匹配调度智能体，实现新业务场景零代码快速接入。
- 网络安全与流量治理：搭建 Spring Cloud Gateway 统一服务入口，集成 JWT-RSA 认证、Redis 令牌桶限流、Resilience4j 熔断降级机制，构建双层安全校验体系，有效防范接口绕过与流量冲击。
- 工具服务标准化改造：将业务查询、订单操作、知识库检索等高频能力抽离为独立 MCP 通用工具服务，支持服务自动注册与发现，消除多智能体工具重复定义与冗余开发问题。

项目亮点：

- 双架构协同：融合路由工作流低延迟与 A2A 协议标准化优势，兼顾调度效率与服务通用性
- 协议分层解耦：A2A 负责智能体调度、MCP 负责工具调用，业务通信与功能调用分层架构，扩展性更强
- 跨技术栈融合：实现 Java 网关与 Python 智能体集群统一编排，打通跨语言服务通信壁垒

商链 2025.5 — 2025.8

项目简介：直播电商 SaaS 履约管理平台，支持多平台订单接入与多商家租户入驻。整合 AI 智能问答与 IoT 设备监控能力，实现仓储履约、设备监测、智能运营问答一体化，助力电商业务高效履约与数字化决策。

技术栈：Spring Boot 3 · Vue 3 + TypeScript · MySQL 8 · Redis · RabbitMQ · Spring AI · Ollama · pgVector · MQTT · InfluxDB · JeecgBoot

个人职责：

- 双大模型集成与流式问答：集成本地与云端双大模型，基于 Spring AI + SSE 实现流式智能问答，支持会话记忆，实现自然语言查询订单、库存等业务数据。
- 全链路业务功能开发：独立完成商家入驻、SKU 管理、出入库、订单履约、库存溯源等前后端业务功能。
- IoT 设备监控体系：基于 MQTT + InfluxDB 搭建设备监控体系，完成数据采集、消息解耦、实时大屏与异常告警功能。

项目亮点：

- 采用 AI + IoT 双驱动架构，实现智能运营与设备监控一体化，构建履约全流程智能化闭环
- 依托私有化 RAG 知识库，大幅提升电商业务问答准确率，有效优化大模型生成效果
- 基于多租户 SaaS 架构，实现多商家数据隔离，适配多店铺批量运营场景

数策 2025.1 — 2025.4

项目简介：面向电商与内容运营场景的轻量化智能数据分析平台，集成数据统计可视化与 AI 智能分析能力，实现业务指标监控、数据诊断、智能总结，为运营决策提供高效数据支撑。

技术栈：Spring Boot · MyBatis-Plus · MySQL · Redis · RabbitMQ · Vue 3 · ECharts · Spring AI · Ollama

个人职责：

- 核心业务开发：主导流量、订单、收益等业务指标的聚合统计与定时刷新，保障数据精准实时。
- AI 智能分析：整合 Spring AI 大模型能力，实现数据智能解读、异常诊断、运营报告自动生成及自然语言问答。
- 可视化数据看板：搭建多维数据筛选、趋势展示与数据排行看板，优化前端交互体验。

项目亮点：

- 融合数据可视化与 AI 智能分析，实现数据展示、解读、总结一体化，大幅降低运营分析成本
- 基于缓存 + 异步架构优化大数据统计场景，系统响应快、并发能力强
- 多维可视化看板直观呈现业务趋势，助力快速定位数据问题、辅助精细化运营决策

项目成果

- 搭建 FAQ + RAG 双引擎检索体系，结合重排序优化，知识库问答准确率提升 55%，彻底解决大模型幻觉问题。
- 创新父子块检索策略，兼顾检索精度与上下文完整性，业务问题解决率提升 50%。
- 搭建多智能体协同中台，通过 A2A + MCP 协议分层解耦，业务场景接入成本降低 60%。
- 基于 Nacos 全量热更新方案，服务运维与参数变更效率提升 70%，无需重启服务、零业务停机。
- 私有化 RAG 知识库优化垂直电商问答，智能问答准确率提升 55%，有效解决大模型幻觉与滞后性问题。
- 自研 Function Calling 业务查询能力，实现对话式数据查询，日常运营查询效率提升 60%。